

Linear Regression

$$RSS = e_1^2 + e_2^2 + \dots + e_n^2$$

$$= (y_1 - \hat{y}_1)^2 + \dots + (y_n - \hat{y}_n)^2$$

Single Linear Regression : $y = \beta_0 + \beta_1 x$ model 이어서
 최상의 $\hat{\beta}_0$ 과 $\hat{\beta}_1$ 을 구하기 위해서 RSS를 minimize한다.


$$RSS = \sum_{i=1}^n (y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2$$

이제 RSS를 minimize하는 $\hat{\beta}_0$ 과 $\hat{\beta}_1$ 은 각각으로 RSS를 미분한다.

$$\frac{\partial RSS}{\partial \hat{\beta}_0} = 0 \quad , \quad \frac{\partial RSS}{\partial \hat{\beta}_1} = 0 \quad \text{이 되도록 해보자. (이걸 만족하면 max or min이다)}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad \rightarrow \quad \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

* Single Linear Regression에서 최상의 $\hat{\beta}_0$ 과 $\hat{\beta}_1$ 을 얻기 위해서
 RSS를 각각 $\hat{\beta}_0$ 과 $\hat{\beta}_1$ 로 미분해서 구한다.



<평가방법>

$RSS \Rightarrow e^2$ 의 sum $\#$ data \uparrow error \uparrow

$RSE, RMSE \Rightarrow$ data를 따른다.

$\sqrt{\frac{RSS}{n-2}}$ $\sqrt{\frac{RSS}{n}}$
 $R\text{-square} : 1 - \frac{RSS}{TSS}$
 (이전 보자) \rightarrow 우리의 모델이 오차의 양
 \rightarrow 실제 관측치의 양
 \rightarrow $\sum_{i=1}^n (y_i - \bar{y})^2$
 \rightarrow model이 이제 설명하지 못한 변동.

Maximum likelihood

왜 log를 사용하냐? 그냥 abs()를 사용해도 되는 거 아닌가?

IID: Independent and Identically distribution

⇒ 모든 사건이 독립이고, 동일한 확률분포를 따른다.

무로 data들이 어느 분포에서 얻어졌는지 모르기 때문에 몇번만 반복해서 실험을 하는 것만으로도 IID를 따르라고 가정한다.

Likelihood: 이미 관측된 data가 있을 때, 그 data를 가장 잘 설명해 주는 분포 parameter θ 를 찾는 것.
일반적으로 θ 가 주어졌을 때 data가 나올 확률 $p(\text{data}|\theta)$ 라면
가능도 함수를 θ 를 확률변수로 두고 $p(\theta|\text{data})$ 를 의미한다.

그래서 $L(\theta; x_1, x_2, \dots, x_n)$ 이 가능도이다.

↑
n개의 data가 관측된 경우
↓
 θ 값

↓
IID가 성립하기

$L(\theta; x_1, x_2, \dots, x_n) = p_\theta(x_1) \cdot p_\theta(x_2) \cdots p_\theta(x_n)$ 이 된다.

즉 모든 확률값들을 maximize하는 θ 를 찾아서 가능도 함수의 특성이야.

* Distribution의 모형은 미리 가정 (예를 들어 Gaussian, 나폴레옹 ---)

그래서 Gaussian인 경우 μ 와 σ 를 찾게 되는 것이다.

Log-likelihood: 여하의 maximize, minimize를 구하기

↗ ↘ 를 곱해서 해당 value는 변화 X.
monotonous increasing 하기.


$$\log \prod_{i=1}^n p_\theta(x_i) = \sum_{i=1}^n \log p_\theta(x_i)$$

각항에 gradient 구하기 용이

$$\arg \max_x f(x) = \arg \max_x \log f(x)$$

MLE : Maximum Likelihood Estimation

$$\begin{aligned}\hat{\theta}(x_1, x_2, \dots, x_n) &= \underset{\theta}{\operatorname{argmax}} L(\theta; x_1, x_2, \dots, x_n) \\ &= \underset{\theta}{\operatorname{argmax}} l(\theta; x_1, x_2, \dots, x_n) \\ &= \underset{\theta}{\operatorname{argmax}} \sum_{i=1}^n \log p_{\theta}(x_i)\end{aligned}$$



<MLE 예시 : Bernoulli distribution>

$$\underset{\theta}{\operatorname{argmax}} \sum_{i=1}^n \log p_{\theta}(x_i) = \underset{\theta}{\operatorname{argmax}} \sum_{i=1}^n \log (\theta^{x_i} (1-\theta)^{(1-x_i)})$$

$$= \underset{\theta}{\operatorname{argmax}} \log \theta \sum_{i=1}^n x_i + \log (1-\theta) \sum_{i=1}^n (1-x_i)$$

$$\frac{2(\log \theta \sum_{i=1}^n x_i + \log (1-\theta) \sum_{i=1}^n (1-x_i))}{2\theta} = 0 \text{ 을 풀면}$$

$$\theta = \frac{1}{n} \sum_{i=1}^n x_i \text{ 가 된다. 자연스레 평균값이 나오게 된다.}$$

2번 미분해서 Hessian 을 구함

$$\frac{2^2 l(\theta)}{2\theta^2} = -\underbrace{\left(\frac{1}{\theta^2}\right)}_{+} \underbrace{\sum_{i=1}^n x_i}_{+} - \underbrace{\left(\frac{1}{(1-\theta)^2}\right)}_{+} \underbrace{\sum_{i=1}^n (1-x_i)}_{+} \therefore 0 \text{보다 작다.}$$

< MLE 예시 : Gaussian distribution >

$\theta = \{\mu, \sigma\}$ 이다. // μ 와 σ 의 값이 모두 미분가능하다.

$$\begin{aligned}\hat{\theta}(x_1, x_2, \dots, x_n) &= \underset{\theta}{\operatorname{argmax}} \sum_{i=1}^n \log \frac{1}{\sigma\sqrt{2\pi}} \cdot e^{-\frac{1}{2}\left(\frac{x_i - \mu}{\sigma}\right)^2} \\ &= \underset{\theta}{\operatorname{argmax}} \sum_{i=1}^n \log \frac{1}{\sigma\sqrt{2\pi}} + \sum_{i=1}^n -\frac{1}{2}\left(\frac{x_i - \mu}{\sigma}\right)^2\end{aligned}$$

$\therefore \mu$ 에 대해 1차 미분시 $\mu = \frac{1}{n} \sum_{i=1}^n x_i$ 가 된다.

σ 에 대해 " $\sigma = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$ 가 된다.

* 정규분포 가시안 가정시 MLE를 통해서 나온 결과이다.

MLE for Linear Regression

기본적인 Linear Regression은 $y = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$ 표현가능

이를 $y = \beta^T x + \varepsilon$ 로 표현 가능하다.

↪ $\varepsilon \sim N(0, \sigma^2)$ 을 따른다고 가정하자.

⇒ 결국 Linear Regression은 $p(y|x) \sim N(\beta^T x, \sigma^2)$

↪ 우리가 원하는 선형을 따르도록 σ 만큼 분산이 존재한다.

이를 MLE를 구하기 위해 가능도 함수를 구하기 되면

$$\arg \max_{\beta} \sum_{i=1}^n \log \frac{1}{\sigma \sqrt{2\pi}} \cdot e^{-\frac{1}{2} \left(\frac{y_i - (\beta^T x_i)}{\sigma} \right)^2}$$

$$\cong \arg \max_{\beta} - \sum_{i=1}^n (y_i - \beta^T x_i)^2$$


$$\arg \min_{\beta} \sum_{i=1}^n (y_i - \beta^T x_i)^2 \quad \left(\text{오차제곱합을 최소화} \right)$$

↪ 이를 최소화하는 β 이다.

행렬로 나타내서 $\frac{\partial \text{RSS}(\beta)}{\partial \beta}$ 를 구하기 되면 $\beta = (X^T X)^{-1} X^T Y$ 가 된다.

↪ 이걸 정사영 Matric이다.

∴ Y 가장 잘 근사하는 β



Bias, Variance and MSE

$$\text{Bias}(\hat{\theta}) = E[\hat{\theta}] - \theta$$

$$\text{Var}(\hat{\theta}) = E[(\hat{\theta} - E[\hat{\theta}])^2]$$

$$\text{MSE} = E\left(\sum_{i=1}^d (\hat{\theta}_i - \theta_i)^2\right)$$

$$\text{MSE} = \text{tr}(\text{Var}) + \|\text{Bias}\|^2$$

$$E\left[\sum_{j=1}^d (\hat{\theta}_j - \theta_j)^2\right] \stackrel{?}{=} \sum_{j=1}^d E[(\hat{\theta}_j - E(\hat{\theta}_j))^2] + \sum_{j=1}^d (E(\hat{\theta}_j) - \theta_j)^2$$

For simplicity, let's suppose $d = 1$ without loss of generality.

$$E[(\hat{\theta} - \theta)^2] \stackrel{?}{=} E[(\hat{\theta} - E(\hat{\theta}))^2] + (E(\hat{\theta}) - \theta)^2$$

- Using the Bias-Variance decomposition, we can compute the MSE of linear regression:

$$\text{MSE}(\hat{\theta}|\mathbf{X}) = \underbrace{\text{Var}(\hat{\theta}|\mathbf{X})}_{\sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}} + \underbrace{\text{Bias}(\hat{\theta}|\mathbf{X})^2}_0 = \sigma^2(\mathbf{X}^\top \mathbf{X})^{-1}$$

- Linear regression is unbiased (bias = 0).
- With infinite data, variance also converges to 0.

- It can be also proved that the MLE is the best unbiased estimator.
 - That is, no other θ has lower variance than the one found by MLE. (Gauss-Markov Theorem)