



여러 Model은 validation set을 기준으로 세워야함.
 (Test는 정답 Never 사용 X)



- (1) 반드시 training set은 클수록이야함 (Training이 ↑ 이면 문제임)
- (2) validation graph는 그려보아서 동향을 파악함.

Training Loss를 계속해서 클수록이면, 어느순간 Validation Loss가 증가하는 경우 "over fitting" 이 발생했다고 함.




Model 학습시 "unseen data"에 강건해야함.

초기에는 train & valid의 common pattern을 학습하지만

학습이 진행될수록 train data의 미세한 pattern까지 학습해서 valid data에 대해 Loss가 증가하게 된다. = over fitting

⇒ feature가 noisy & dimension이 커지는 경우
 (이때 대응하는 data수가 필요하다)

Overfitting 이 Model의 capacity가 높으면 생길 수 있다.



→ train set을 위해
합이러버린다.

즉, 학습가능한 parameter가 많아 model의 capacity이다. (model complexity = complexity)

under fitting : Data pattern 자체를 학습할 용량 X

overfitting : Train Data에 너무 fit하게 학습

↳ "적당하게 Model 크기를 정하고, 적당하게 학습시켜라"

<Early Stopping>

validation Loss가 올라가는 경우 학습 종료!

⇒ 우리가 1D를 가정해볼 때

Train에서 Noise를 학습하는 time이 점점 많은 valid에서도

오류가 생긴다. (valid Loss가 올라가는 순간 ≈ Test Loss가 올라가는 순간 일 것임)

∴ 일정주기 validation Loss를 checker validation ↑이면 stop한다.


이런 기준?

① train에 사용하는 loss function

② 실제 정답과 --- 코스트 차이이다. (overfitting 판단에 유리)
(실제 관측값 metric)

* Metric이라 overfitting 되는 순간이 많아, 최종으로 사용하는 metric으로
valid의 overfitting 여부를 판단하는 게 일반적이다.

< Regularization >



$$(1) y = \beta_0 + \beta_1 x_1 \quad (2) y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 \quad (3) y = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$$

이 Model 또한 (3) 모델에서 $\beta_3 \tau_3 \sim \beta_n \tau_n$ 관계가 유지되면 (2)와 같다.

즉, $y = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$ 관계를 갖게 된다.

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

$$y = \beta_0 + \beta_1 x_1$$

가장 큰 Model(을 만들) β는 2정에서 complexity를 조절 가능
 했어! ≈ 규제량 (정말 Need한 β가 아니면 0으로 만들자!!)

Shrinkage Methods : coefficient (β) 가 0 이 가깝게 만들어주는 방법.

$$R_{\text{reg}} = \sum_{i=1}^n (y - \beta^T x)^2 + \lambda \|\beta\|_2^2$$

* $\lambda \uparrow$ 일수록 β 들이 0에 가까워져

★ 모델은 Simple하다.

(variance ↓, bias ↑)
모두 비슷함 예측이 다름.

가까이여

→ 양의 값 (귀계 정도를 의미) ↑ 이면 거의 $\beta \approx 0$ 이다.

β 가 너무 큰 값을 갖도록 할 수 없다.

가까이여 ϵ^2 가 클수록 β 를 키고

ϵ^2 가 클수록 $\beta < ||\beta||_2$ 이면 그냥 β 를 줄여라!!

β 이 커나감

가까이여 크기 사이의 관계가.


보이 아닌 Logger
파일이나 로그 사이트 남겨주기.

Regularization이 data들의 기본 양이나 다른 양이 적은 data는 penalty로 부러 자름.
 이는 Model이 지대로 학습 X 이 된다.

"그래서 data들은 $\tilde{x}_{ij} = \frac{x_{ij}}{\sqrt{\frac{1}{n} \sum_{j=1}^n (x_{ij} - \bar{x}_j)^2}}$ 로 정규화하여 사용한다"

Linear Regression에선 $\beta = (X^T X + \lambda I)^{-1} X^T y$ 가 된다.

< Ridge (L_2 -regularization) >



< Lasso (L_1 -regularization) >

penalty term이 $\| \beta \|_1$ 이 된다. L_1 Loss는 딱 sparse한 model을 유도 $\Rightarrow \beta$ 를 0으로 만들어준다.


L_2 는 0이 아니라 0이 아닌 값을 갖는다.

\Rightarrow beta가 몇개 살아남을지 맞추기 (lambda로 선택적으로 자름)

해방 영역은 가장 가까운 point가 꼭 붙잡히기. 즉 특성 $\beta = 0$ 은 만족하는 위치이다.
 ($\beta = 0$ 인 영역 > $\beta \neq 0$ 인 영역)

L_1 : 덜 필요한 beta를 부러 0이 됨

L_2 : 모든 beta 관련된 특성 0으로 부러간다.



# of parameters	Small	Large
Model rigidity	Rigid	Flexible
Model complexity	Simple	Complex
Decision boundary	Smooth	Irregular
Regularization	High λ	Low λ
Extreme problem	Underfitting	Overfitting
Bias	High	Low
Variance	Low	High