

unsupervised learning은 data의 숨겨진 pattern이나 의미를 찾는 행위.

⇒ 무슨 factor를 할지도 걱정 정해야 한다.

(1) clustering ⇒ 살짝 무언이 들어맞고 (가끔 무엇인지에 따라서)

동일 cluster의 data들이 공통점 ↑ & 다른 cluster data들 공통점 ↓  
high intra similarity      low inter similarity

① data를 사이 유사성/거리를 나타낼 수 있는 metric을 정해야 한다.

ex)  $L_1(A, B) = \sqrt{A^2 + B^2}$

< 1 - Bottom-up 방식 >


data 각각이 cluster라고 생각해서 진행. n개의 data = n개의 group

< 2 - partition >

모든 data를 1개로 두고 split하는 방법.

## # Bottom up (Hierarchical clustering)

- 1) 모든 data가 각 group
- 2) 초기에는 threshold 임의 ⇒ 원하는 group을 merge
- 3) threshold를 낮추면서 group merging 진행.



cluster들끼리 similarity는? ⇒ 다양한 방법들이 ⇒ 주로 average 사용.

## ## K-Means

- ① k개의 random point
  - ② data 들의 가장 가까운 k에 group화
  - ③ group의 average를 다시 구하고 다시 가까운 data를끼리 group화.
- } repeat.

⇒ 더 이상 group의 averaged 변화가 없으면 terminate.

이를 수식화 해보면 아래와 같이 표현이 가능함.

$$J = \sum_{i=1}^N \sum_{j=1}^K \underbrace{r_{ij}}_{\text{이항부}} \|x_i - \underbrace{\mu_j}_{\text{group의 평균 "centroid"}}\|^2$$

결국 kmeans = minimize J 이다.

주요 Code

$$\begin{aligned} \text{step (1)} \quad & C^{(i)} = \arg \min \|x^{(i)} - \mu_k\|^2 \quad // \text{가장 가까운 group mapping} \\ \text{step (2)} \quad & \mu_k = \frac{\sum_{i=1}^n I(C^{(i)}=j) x^{(i)}}{\sum_{i=1}^n I(C^{(i)}=j)} \quad // \text{centroid update.} \end{aligned}$$


worst:  $O(K^n)$  np hard problem 이지만, 거의 발생 X.

\* C가 계속 변할 경우에만 group을 change ⇒ 그래서 언제까지 끝나는.

Because 모든 점을 다 방문 언제까지 terminate.

\* K가 너무 작아지면 결과가 달라지게 됨.

\* K를 너무 키웠을 경우 Loss는 줄어든다. 그러면 K를 몇번은 설정해주어야 함



K↑ 할수록 Loss는 줄지만

점성 얻는 이득이 줄어든다.


이때 적절한 Elbow를 찾아서 사용.

(vs 여러 직감적으로 고르나)

# Dimension Reduction : 차원 축소만 존재해서 정보를 잃지 않기.

data manifold  $\Rightarrow$  data는 특정 영역에 몰려있다.

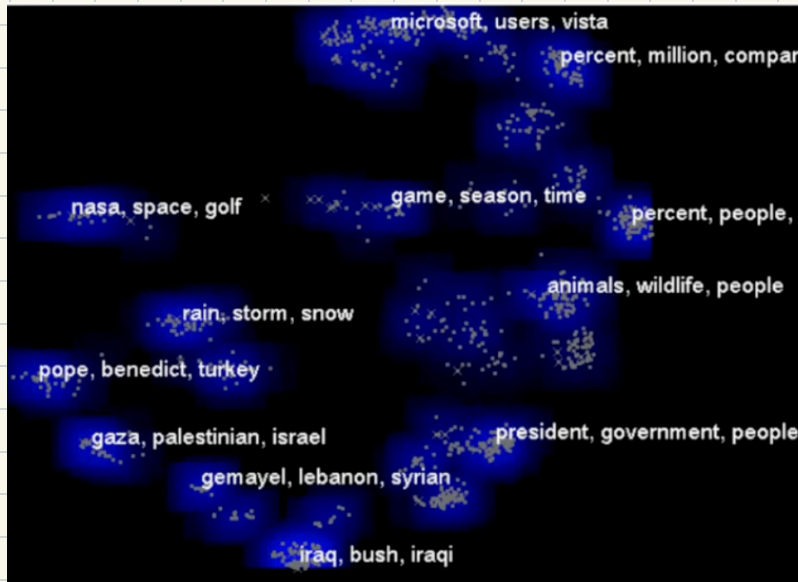
고차원 space에 특정 영역에 몰려있어  $\Rightarrow$  detail만 희생하면 훨씬 낮은 차원으로 data를 분류가능.



general한 경우 manifold Learning (Multidimensional Scaling : MDS) 표현


$$\sum_{i > j} R \left( \underbrace{\|f(x^{(i)}) - f(x^{(j)})\|}_{\text{distance}}, \underbrace{p(x^{(i)}), p(x^{(j)})}_{\text{probability}} \right)$$

차원 축소 이후에도 원래  $p$ 와 비슷하게



단어들의 유사한 의미를 갖는  
단어들이 비슷한 위치에 모이게 된다.

PCA : MDS의 special case



Data를 다루는 가장 중요한 <sup>기술</sup>을 찾는 것이다.

우선 data의 scale을 맞추기 위해 zero-centered & normalized 실행.

data의 error를 minimize 하려면 covariance의 diagonal element가 eigen value가 된다  $\Rightarrow$  즉, eigen value가 ~~큰~~ vector를 ~~큰~~ factor가 된다.

PCA의 dimension 또한 kmeans와 비교 가능.

