

Linear classifier의 문제점.

: template (w)가 class당 1개만 존재하여 여러 보충을 갖춘 class에 취약하다.
input → output 형태 자체가 Linear boundary만 생성 가능. (정확도 ↓)

↳ Linearly seperable 하지 특정 변환을 해주는 방법을 쓸수도 있다.

이미지의 feature를 뽑아서 분해해보자 ⇒ edge, 색상 list ...) 직접적 방법

아무튼 이미지 전체를 사용하기 보나 **이미지의 중요 feature만** 사용해서 이미지는 분류 가능!
↳ 그래서 feature를 어떻게 만들건데?


* **Model이 스스로 feature를 추출하기** ⇒ 각각 feature로 예측까지 **End-to-End**로 설계해야
나중 아이디어가 deep Learning의 시작이다. 해명적 접근...!

End-to-End가 Always 중요하다

⇒ 특정 domain의 pattern을 알기 위해 충분한 resource가 필요. , human이 갖고있는 사전지식인 domain 지식을 활용하면 효율 ↑일 수 있다. <사전지식인 domain knowledge이 중요하다>

perception ⇒ $y = f(w_1x_1 + w_2x_2)$

$$f(a) = \begin{cases} 0 & (a \geq \theta) \\ 1 & (a < \theta) \end{cases}$$




특정 θ 를 넘어서지 않는(상승)을 방지하는 방법을 그래프 사용.

Single perception의 장벽: "XOR"을 만들수가 없다.

↳ Multi perception으로 우회 가능!

$$y = f(w_5 f(w_1x_1 + w_2x_2) + w_6 f(w_3x_1 + w_4x_2))$$



MLP (Multi Layer perceptron)

MLP에서 약자 \approx activation function을 사용하지 않으면 single perceptron과 동일하다.

$$f(w_2(w_1x)) = f((w_2w_1)x) = f(wx) \text{ 가 되기 때문이다}$$

그래서 MLP 핵심은 activation function이다. = non-Linear function.


Computing gradients (w 학습하기)

gradient로 loss function을 minimize 하도록 w를 바꾸자

$$\hat{y} = w_2 \cdot \sigma(w_1x_1) \Rightarrow \frac{\partial L}{\partial w_1} \& \frac{\partial L}{\partial w_2} \text{ 을 계산한다.}$$

Backpropagation

Chain rule이 위해서 필요로 된다.



Gradient pattern.


\oplus \Rightarrow 그냥 gradient를 똑같이 흘린다

\otimes \Rightarrow gradient를 change해서 보낸다.


\max \Rightarrow input이 큰 곳으로만 gradient를 보낸다.

copy \Rightarrow gradient를 sum 해서 출력보낸다.


add gate: gradient distributor



mul gate: "swap multiplier"



copy gate: gradient adder



max gate: gradient router



스칼라를 vector로 미분 \Rightarrow vector

vector를 vector로 미분 \Rightarrow matrix